VILNIAUS UNIVERSITETAS
MATEMATIKOS IR INFORMATIKOS FAKULTETAS
INFORMATIKOS KATEDRA

Kursinis projektinis darbas

Dokomentų klasterizacija

(Document clustering)

Atliko: 4 kurso 1 grupės studentas
Dominykas Ablingis (parašas)

Darbo vadovas:
Prof., Dr. Rimantas Kybartas (parašas)

Vilnius
2018

Turinys

Įvadas

Šio darbo tikslas yra aprašyti lietuviškų tekstinių dokumentų parengimo klasterizavimui žingsnius, išanalizuoti naudotus metodus ir rezultatus, gautus taikant skirtingus klasterizavimo algoritmus, bei įvertinti suklasterizuotų tekstinių dokumentų kokybę.

Duomenų analizės eiga

Klasterizavimas tėra vienas iš žingsnių tekstinių duomenų analizės procese. Tekstinių duomenų analizės procesą galime suskirstyti į keletą žingsnių [FPS96]:

1. Probleminės srities nustatymas (angl. *problem domain*) .
2. Duomenų surinkimas (angl. *data collection*) .
3. Duomenų tvarkymas ir apdorojimas (angl. *cleaning and preprocessing*) [1].
4. Duomenų supaprastinimas ir transformavimas (angl. *reduction and projection*) .
5. Duomenų analizavimas (angl. *data analysis*) .
    5.1. Panašumo matas (angl. *proximity measure*)
    5.2. Panašumo matas (angl. *proximity measure*)
6. Rezultatų validavimas / įvertinimas (angl. *validation of results*)
7. Rezultatų interpretavimas (angl. *interpretacion of results*)
8. Rezultatų panaudojimas.

Ankstesniame darbe aprašiau 2, 3, 4 ir 6 žingsnius, šiame ir įsigilinsiu į juos.

[1] 3 ir 4-tas žingsniai gali būti apibrėžti kaip požymių pasirinkimas (angl. *feature selection*) . Svarbu atrinkti požymius, kurie yra esminiai atskiriant objektus ir juose būtų konkreti informacija užduočiai atlikti, tuo pačiu stengiantis palikti kuo mažiau perteklinės informacijos ir neprarasti svarbios informacijos.

1. Tekstinio duomenų rinkinio parengimas

Rengiant tekstinį duomenų rinkinį klasterizavimui, teksto paruošimo (angl. *text preprocessing*) metu tekstą iš patogios žmogui ar kitoms programoms formos verčiame į formą tinkamą duomenų analizei. Tam tekstinį dokumentą pirmiausia reikia papildomai apdoroti, t. y. jį supaprastinti, pašalinti nereikalingus ir nereikšmingus žodžius, stengiantis neprarasti mūsų uždavinio sprendimui vertingos informacijos. Po to, tekstinius duomenis reikia paversti į skaitmeninius, kad galėtume taikyti klasterizavimo algoritmus. Šiame skyriuje bus aptartos šios problemos ir jų sprendimo būdai.

1.1. Duomenų išgavimas

Dirbant su iš anksto neparuoštu duomenų rinkiniu (angl. *data set*) , pirmas žingsnis yra duomenų iš įvairių šaltinių išgavimas (angl. *information retrieval*) [KCA14]. Tekstiniai duomenys gali būti išgaunama iš tokių šaltinių:

- **Analoginiai šaltiniai**. Tai knygos, kurias galime nuskenuoti ir duomenų rinkinį parengti, pasinaudojus teksto atpažinimo programomis (angl. *optical character recognition, OCR*) . Taip pat tekstinius duomenis galime išgauti iš audio įrašų, pasinaudojus šnektos atpažinimo (angl. *speech recognition*) programomis.
- **Skaitmeniniai šaltiniai.** Įvairūs dokumentai (PDF), elektroninės knygos (ePub, MOBI), mokslo darbai (Tex), internetinės svetainės ir kiti.

Šiame skyriuje orientuosiuosi į keletą tekstinių duomenų išgavimo iš internetinių svetainių būdų (skaitmeninis šaltinis).

Dalis internetinių svetainių suteikia aplikacijų programavimo sąsają (API), kurios pagalba galima patogiau išgauti mums reikiamus duomenis. Tačiau svetainėms, kurios nesuteikia API, gali tekti suprogramuoti interneto robotą (angl. *web crawler*) , kurio paskirtis naršyti po svetainę ir rinkti reikalingus duomenis[2]. Po to surinktus duomenis reikia išanalizuoti (angl. *parse*) .

Internetinės svetainės aprašomos HTML maketavimo kalba. HTML dokumentai yra sudaryti iš `<elementų>`ir turinio`</elementų>`. HTML dokumente elementai gali turėti daug skirtingų nurodymų naršyklei: teksto anotacijos, nurodymai kokį formatavimą pritaikyti tekstui, kaip formatuoti patį puslapį, nuoroda į kitą puslapį, patalpinti paveiksliuką ir daug kitų. Dėl HTML dokumente esančios informacijos įvairovės ir skirtingų informacijos išdėstymo galimybių, nėra paprasta universaliai atskirti svetainės straipsnio tekstą nuo navigacijos, komentarų, kontaktų ir panašiai. Ši problema sprendžiama keliais būdais:

- Pirma, galime pasinaudoti tuo, kad HTML dokumentai yra išdėstyti kaip medžio struktūra (DOM). Taigi specifinei svetainei galime nurodyti kaip medžiu nukeliauti iki straipsnio šakos ir išgauti turinį (tam skirtos programos vadinamos „HTML *parsers*“). Deja, skirtingos

[2]Labai svarbu atkreipti dėmesį į svetainės nurodytą `robot.txt` failą, kuriame išdėstyti reikalavimai.

svetainės skirtingai realizuoja medžio struktūrą. Todėl šis metodas tinkamas tik tuo atveju, jeigu dirbame su straipsniais gautais iš vienos svetainės.

- Jeigu puslapis realizuotas HTML5 standartu, straipsnio tekstą turėtume rasti tarp `<article>` elementų. Tuo tarpu kitos dokumento dalys gali būti atitinkamai `<header>`, `<footer>`, `<nav>` elementuose. Praktikoje tai ganėtinai reti atvejai.

- Interneto naršyklės Safari, Firefox ir Edge turi savyje realizuotą skaitymo funkciją, kuri iš svetainės išgauna straipsnio tekstą ir jį pateikia patogesne skaitymui forma (pašalina nereikalingus navigacijos elementus, reklamas, komentarus ir kita, bet palieka formatavimą ir paveiksliukus). Firefox naršyklė yra atviro kodo, todėl pateikia šio funkcionalumo realizaciją[3].

1.2. Teksto filtravimas

Kolekcijos žodynas yra sudaromas iš dokumentų tekste esančių žodžių. Savaime suprantama, kad realiuose dokumentuose ne visi jų turinį sudarantys žodžiai yra vienodai reikšmingi. Žodžiai gali turėti daug skirtingų formų, semantinių atitikmenų, tokias kalbos dalis kaip įvardžiai, prielinksniai ir pan., kurie nesuteikia daug informacijos. Dėl šios priežasties, sudarant dokumentų kolekcijos žodyną, atliekamas žodžių filtravimas ir teksto matmenų sumažinimas (angl. *dimensionality reduction*) . Šiame poskyryje bus aprašytas filtravimo procesas.

Gali atrodyti, kad sudarytas filtruotas žodynas blogai reprezentuos originalų dokumentą, tačiau, kaip rodo praktika, teksto matmenų sumažinimas gali net padidinti klasterizavimo efektyvumą ir tikslumą [MPP].

1.2.1. Leksikos analizė

Leksikos analizė (angl. *lexical analysis, tokenization*) – tai dažniausiai būna pirmas teksto apdorojimo žingsnis. Jo metu iš neapdoroto teksto yra išgaunami atskiri žodžiai (angl. *tokens*) ir patalpinami į patogią duomenų struktūrą tolesniam apdorojimui. Šiame etape taip pat panaikinami visi skyrybos ženklai, nespausdinami simboliai ir skaičiai. Tam dažniausiai naudojama žodžių maišelio (angl. *bag of words*) duomenų struktūra (nors ir prarandamas teksto eiliškumas). Vėliau šie žodžiai bus panaudojami kaip indeksai žodyne. Nors iš pirmo žvilgsnio atrodo paprasta, leksikos analizė kai kurioms sudėtingesnėms kalboms vis dar yra problematiška ir aktyviai tiriama sritis. Teksto apdorojimui taip pat yra problematiški žodžiai su atskiriamaisiais ženklais viduje, pavyzdžiui, I.B.M.; Vincas Mykolaitis-Putinas; O'Reilly; pre-diabetes. Tokiems atvejams yra keli galimi sprendimai:

- Atskirti juos į atskiras raides ir laikyti juos žodžiais. Šis metodas gali iš atskirų raidžių sukurti beprasmius žodžius. Pavyzdžiui, „I.B.M“.

[3] https://github.com/mozilla/readability

- Sujungti į vieną žodį, bet šis metodas didina riziką prarasti dalį informacijos. Pavyzdžiui, atsisakę brūkšnelio ir sujungę „pre-diabetes“ į vieną žodį, prarasime panašumą su panašios prasmės žodžiu „diabetes“.

- Paprasčiausias ir efektyvus šių problemų sprendimas – atlikti atskyrimą ir sujungimą (I.B.M = I, B, M; IBM). Tik reikia atkreipti dėmesį, kad naudojant šį metodą, duomenyse atsiranda daugiau triukšmo, bet vėlesni žingsniai turėtų tą problemą išspręsti.

1.2.2. Nereikšmingų žodžių pašalinimas

Sudarant tekstinių dokumentų žodyną, galima neįtraukti dažnai vartojamų nereikšmingų (angl. *stop-word*) , bet visuose dokumentuose pasitaikančių, žodžių. Tokios kalbos dalys kaip jungtukai, dalelytės, prielinksniai, įvardžiai turi palyginti mažai reikšmės ir yra kaip teksto„klijai“. Išmetus šiuos žodžius, paspartėja analizė ir pagerėja jos rezultatai. Lietuviškuose tekstuose nereikšmingos kalbos dalys sudaro apie 23 procentus[4] žodžių [Utk09].

Reikia atkreipti dėmesį, kad skirtingose srityse nereikšmingų žodžių žodynai gali skirtis (pvz., internete žodis „nuoroda“ kur kas dažniau sutinkamas nei kitose srityse ir gali būti laikomas nereikšmingu). Taip pat kai kurios frazės gali būti sudarytos iš atskirai nereikšmingų žodžių, bet būdamos kartu gali turėti prasmę („to be or not to be“).

Šiai problemai spręsti įprastai sudaromas arba naudojamas specifinis kalbos ir srities žodynų junginys (angl. *top-word dictionary*) . Jeigu nėra galimybės gauti jau sudaryto žodyno, galima jį sugeneruoti iš turimų žodžių, atmetus populiariausius. Tai detaliau aptarsiu 1.3 skyriuje.

1.2.3. Sinonimų ir daugiareikšmių žodžių analizė

Sinonimai – tai žodžiai, kurie rašomi skirtingai, bet turi tą pačią (ar panašią) reikšmę. Pavyzdžiui, žodžiai arklys, žirgas ir kuinas daugeliu atveju turi labai panašią reikšmę.

Daugiareikšmiai žodžiai (angl. *polysemy*) – žodžiai turintys daugiau nei vieną reikšmę. Ši problema ypač aktuali ir sudėtinga dirbant su lietuviškais tekstais, kai tas pats žodis gali turėti kelias prasmes. Pavyzdžiui, sakaĩ (daiktavardžio daugiskaitos vardininkas) ir sakaĩ (veiksmažodžio sakyti esamojo laiko 2-as asmuo), žodis „leisti“ gali reikšti: duoti sutikimą, sudaryti sąlygas ir kita. Šią problemą dažniausiai galima išspręsti tik analizuojant aplinkinį tekstą (kontekstą).

Žodžių sinonimiškumo ir daugiareikšmiškumo problemoms spręsti yra keli metodai:

- Pasinaudoti jau sudarytais specialiais žodynais.

  - Geriausia situacija, kai dirbame su konkrečia sritimi, kuriai yra sudarytas žodynas. Pavyzdžiui, dirbant su medicininiais tekstais galime pasinaudoti MeSh (*Medical Subject Headings*) žodynu.

[4] Įvardžiai – 8,71 %, prielinksniai – 4,65 %, jungtukai – 7,62 %, dalelytės – 1,98 %.

– Pati populiariausia anglų kalbos duomenų bazė yra Wordnet[5]. Joje žodžiai sugrupuoti pagal prasmę ir nurodyti ryšiai tarp žodžių ir žodžių grupių, taip pat yra aprašymai ir pavyzdžiai. Analogiški žodynai yra parengti ir kitoms kalboms, įskaitant ir lietuvių kalbą[6]. Tačiau šios duomenų bazės yra labai sudėtingos ir didelės apimties, tai apsunkina pasinaudojimą jomis. Taip pat jose nėra specifinių sričių žodžių bei galimybės paprastai perteikti konteksto, kuriame buvo panaudotas žodis.

- Pritaikius statistinius metodus, ieškoti žodžių porų, kurias galima sutikti panašiame kontekste [BB04]. Deja, bet šio metodo taikymui reikia turėti didelį kiekį pavyzdinio teksto ir gauti rezultatai gali turėti klaidingai teigiamų (angl. *false positive*) porų.

- Taip pat galime nurodyti vartotojui, kad jis parinktų, kuri sinonimo reikšmė yra tinkamesnė kontekste. Tokiu būdu problemos sprendimas paverčiamas į prižiūrimo mokymosi (angl. *relevance feedback*) problemos sprendimą.

Norint efektyviai išnaudoti sinonimus, tam reikia sudėtingų metodų ir duomenų struktūrų, o tai gali smarkiai apsunkinti klasterizavimą. Todėl sinonimų analizė dokumentų klasterizavime, naudojama palyginti retai. Ši analizė yra kur kas svarbesnė paieškos variklių kūrime, nes čia vartotojas pateikia palyginti labai nedidelį kiekį duomenų (užklausą), o norima išgauti kuo daugiau informacijos iš jų.

1.2.4. Morfologinė analizė

Žodžiai gali turėti daug skirtingų morfologinių formų, bet duomenų analizės atveju, jos dažnai nėra reikšmingos. Todėl kaip ir ankstesniuose filtravimo žingsniuose, reikėtų supaprastinti tekstų žodyną morfologine prasme. Šiai problemai išspręsti yra sukurta daug skirtingų metodų, bet jie visi bando rasti balansą tarp realizacijos sudėtingumo, veikimo greičio ir tikslumo. Taip pat skirtingoms kalboms reikia skirtingo sudėtingumo metodų. Kai kurioms kalboms tai vis dar neišspręsta problema ir aktyviai tyrinėjama sritis (pvz., arabų ir hebrajų kalboms). Nežiūrint į visa tai, visus morfologinius analizatorius galima suskirstyti į dvi grupes.

Kamieno atskyrimo programos (angl. *temmer*) – išgauna žodžių kamienus. Egzistuoja keli realizacijos būdai:

- Paremti taisyklėmis ir išimčių žodynu. Kokybiškai sistemai sukurti taisyklių parengimas ir visų išimčių išrinkimas reikalauja daug žmogiškųjų išteklių, todėl tokios sistemos yra sukurtos tik populiarioms ir paprastoms kalboms.

- Paremti tikimybėmis. Pirmiausia šiuos algoritmus reikia apmokyti, kaip atpažinti kalbos dalis su iš anksto anotuotais tekstais. Tada algoritmas sugeba su tikimybe nuspėti kuriai kalbos daliai priklausytų žodis ir pagal tai parenka kaip išgauti žodžio kamieną.

[5]https://wordnet.princeton.edu/
[6]urlhttp://korpus.sk/ltskwn_lt.html

Lemuokliai (angl. *lemmatizer*) – išgauna pirmines žodžių formas (lemas). Tai kur kas sudėtingesnė problema, nei kamieno atskyrimas. Dažnai reikia žinoti kokiame kontekste buvo panaudotas žodis[7], kad nustatytume kuriai kalbos daliai jis priklauso ir galėtume teisingai išgauti pirminę formą. Tačiau žodžiai gauti lemuoklio pagalba yra aiškesni, negu tik žodžių kamienai. Taip pat lemuoklis grąžina labiau praretintą tekstynų žodyną. Pavyzdžiui, lemuoklis gavęs žodžius „yra, esu, buvo“ grąžintų žodį „būti“.

1.3. Požymių išskyrimas

Norint atlikti tekstinių duomenų analizę su dauguma klasterizavimo metodų, pirmiausia tekstai turi būti pateikiami skaitine išraiška, todėl iškyla problema, kaip tinkamai paversti tekstinius duomenis į skaitinius. Nors yra daugybė požymių išskyrimo (angl. *feature extraction*) technikų, bet geriausiai naudoti tas, kurios pritaikytos duomenų tipui [ATL13]. Todėl šiame darbe paminėsiu tik su tekstiniais duomenimis susijusius metodus.

1.3.1. Žodžių maišas

Žodžių maišas (angl. *bag of words*) – pats paprasčiausias metodas. Surenkame visus unikalius žodžius tekste ir prie jų priskiriame skaičių, nurodantį kiek kartų jie pasikartojo konkrečiame dokumente. Kitaip tariant, kiekvienam dokumentui sukuriame multiaibę (angl. *multiset*) .

1.3.2. Vektorinės erdvės modelis

Vektorinės erdvės modelis (angl. *vector space model*) paverčia visus duomenis vektoriais, dokumentų klasterizavimo atveju, tai yra žodžiais ir dokumentais. Sukuriame matricą, kurios stulpeliai atitinka surinktus dokumentus, eilutės visus atrinktus žodžius (kaip pavaizduota 1 paveikslėlyje). Yra keletas būdų matricos elementams priskirti reikšmes, dar vadinamas svoriais. Paprasčiausias metodas, priskirti binarinius svorius, jei žodis yra dokumente – 1, jeigu ne – 0. Bet šis metodas praranda informaciją apie žodžių dažnius. Toliau aptarsime sudėtingesnius svėrimo metodus.

[7] Kai kurie lemuokliai gavę tik vieną žodį, grąžina visų įmanomų lemų sąrašą.

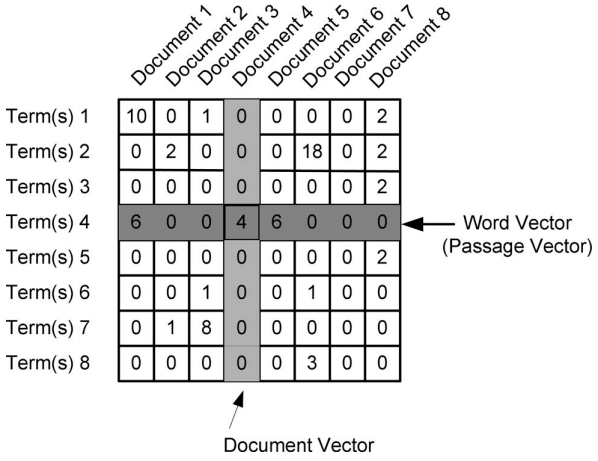

1 pav. Vektorinės erdvės modelio pavizdys: eilutės žodžių vektoriai, stulpeliai dokumentų vektoriai. Šaltinis: [MCS14]

1.3.3. Terminų dažnis

Terminų dažnis (angl. *term frequency*) (toliau TF) vienas pirmųjų ir paprasčiausių svėrimo metodų. Tekstų rinkinyje dokumentai, kurie priklauso tai pačiai temai, labiau tikėtina, kad naudos panašius žodžius. Taigi, dažniau pasikartojantys žodžiai bus geri tam tikrų temų indikatoriai.

Yra įvairių būdų apskaičiuoti TF, bet populiariausias – suskaičiuoti kiek kartų terminas *t* pasikartojo konkrečiame dokumente *d* (panašiai kaip žodžių maišo metodas).

$$\text{tf}(t,d) = f_{t,d}$$

1.3.4. Atvirkštinis dokumentų dažnis (IDF)

Nors TF yra efektyvus terminų parinkimui, bet jis nėra efektyvus priskiriant jiems svorius, nes terminai su panašiais svoriais gali turėti drastiškai skirtingus pasiskirstymus. Žodis, kuris dažnai pasirodo visuose dokumentuose (pvz., jungtukas „ir“) turės didelę TF reikšmę, bet visiškai nepadės mums suskirstyti dokumentų į grupes. Tuo tarpu žodis, pasirodantis mažoje dokumentų grupėje, gali būti kur kas vertingesnis. Todėl, norėdami sureguliuoti terminų svorius, naudojame atvirkštinį dokumentų dažnį (angl. *inverse document frequency*) (toliau IDF).

IDF išmatuoja ar terminas yra dažnas, ar retas tarp visų dokumentų. Tai populiariausias ir paprasčiausias metodas ir skaičiuojamas taikant formulę:

$$\text{idf}(t, D) = \log \frac{N}{|\{d \in D : t \in d\}|}$$

N – bendras dokumentų kiekis,
$|\{d \in D : t \in d\}|$ – kiek dokumentų turi terminą t.
Taigi, IDF reikšmė bus didesnė retiems terminams, mažesnė – dažniems ir lygi 0 terminams, kurie pasitaiko visuose dokumentuose.

IDF pirmą kartą buvo paminėta [Spa72] ir paremta empiriniais tyrimais, kurie rodo, kad beveik pusė žodžių yra sutinkami tekstyne tik po vieną kartą [Pia14]. Šis reiškinys yra žinomas kaip Zipfo dėsnis.

1.3.5. TF-IDF

TF-IDF (angl. *term frequency-inverse document frequency*) yra vienas populiariausių žodžių svėrimo metodų [Research-paper recommender systems: a literature survey]. Jį gauname sujungus anksčiau minėtus metodus į vieną[8]:

$$\text{tfidf}(t,d,D) = \text{tf}(t,d) \cdot \text{idf}(t,D)$$

TF-IDF apibrėžimo seka kelios savybės:

- Didžiausi svoriai priskiriami terminams, kurie dažnai pasirodo mažoje dokumentų grupėje.
- Tarp daugumos dokumentų pasirodantys žodžiai turės mažesnius svorius, o žodis aptinkamas visuose dokumentuose svers 0.

Šie metodai gali ypač padėti tais atvejais, kai neturime nereikšmingų žodžių žodyno. Šiame žingsnyje net galime sumažinti žodyno dydį: panaikindami žodžius, kurie pasikartoja visuose ar daugumoje dokumentų ir žodžius, kurie pasirodo tik viename dokumente, nes abiem atvejais jie nebus vertingi klasterizavime.

1.3.6. Kiti metodai

Šiame skyriuje aprašyti metodai turėjo keletą rimtų trūkumų, todėl tokioms problemoms spręsti yra sukurta keletas skirtingų metodų:

- Iš kasdienio gyvenimo žinome, kad vieni žodžiai yra tikėtina dažniau sutinkami nei kiti. Todėl pavertus juos vektoriais, negalime tikėtis, kad jie bus tiesiškai nepriklausomi. Tokie metodai kaip **word2vec** atsižvelgia į žodžių artumą, kuriant vektorius [MCC+13].
- Išskaidydami tekstus į atskirus žodžius, prarandame informaciją apie jų eiliškumą. Egzistuoja metodai, kurie atsižvelgia į aplinkinius žodžius, kuriant vektorius pvz., **GloVe** [PSM14].

[8] Dirbant su skirtingos apimties dokumentais, yra būdai svoriams normalizuoti atsižvelgiant į dokumentų dydį.

2. Klasterizavimo algoritmų analizė

Klasterizavimas tai viena iš neprižiūrimo mokymosi sričių. Jos tikslas – sugrupuoti duomenis į klasterius, neturint ankstesnės informacijos kaip jie turėtų atrodyti.

- **Atstumas** – Visų pirma, turime apibrėžti atstumo tarp analizuojamų objektų (duomenų) matą. Yra sukurta daugybė skirtingų matų ir dažnai jų parinkimas priklauso nuo to, kokius duomenis analizuojame. Ankstesniuose žingsniuose tekstus pavertėme į skaitmeninius duomenis, todėl galime panaudoti daugumą populiarių matų.

Klasterizavimo metodai:

- **K-vidurkių** (angl. *k-means*) – šis metodas sukuria *k* centroidų, kurie atitinka klasterio objektų reikšmių vidurkį. Tada iteratyviai vis tikslinama, kurie objektai kuriam centroidui turėtų priklausyti ir kokioje padėtyje turėtų būti patys centroidai. Galiausiai, kai skirstymas stabilizuojasi, turime sudarytus klasterius.

- **Lūkesčių-maksimizavimo** (angl. *expectation–maximization*) – veikimo principas labai panašus į k-vidurkių metodą, tik vietoje centroidų naudojami Gauso pasiskirstymai. To rezultate, objektai priklauso kiekvienam klasteriui su tikimybe.

- **Hierarchinis** (angl. *hierarchical*) – skirtingai nei ankstesni metodai, šis sugeneruoja ne atskirus klasterius, bet klasterių hierarchiją. Dėl to galime duomenyse atrasti kur kas sudėtingesnes struktūras. Bet šis metodas reikalauja, kad papildomai apibrėžtume kaip matuojami atstumai tarp klasterių.

- **DBSCAN** (angl. *density-based spatial clustering of applications with noise*) – metodas kurdamas klasterius remiasi objektų tankiu. Objektai, kurie turi šalia savęs pakankamai kaimyninių objektų, virsta klasteriais ir plečiasi kol surenka visus pakankamai tankius kaimyninius objektus. Šis metodas sėkmingai ignoruoja triukšmą, laikydamas jį nepakankamai tankia zona. Taip pat gali sudaryti sudėtingos formos klasterius, vienas klasteris gali net pilnai apsupti kitą.

Be šių yra dar daugybė skirtingų klasterizavimo metodų ir modifikacijų. Nėra vieno geriausio universalaus metodo, kiekvienas iš jų turi privalumų ir trūkumų, todėl reikia parinkti metodą, atsižvelgus į turimus duomenis ir norimus gauti rezultatus.

3. Kokybės vertinimas

Visi klasterizavimo metodai turi bendrą silpnybę – jų paskirtis atrasti duomenų struktūras, tačiau jie gali atrasti jas ir tais atvejais, kai duomenyse nėra jokių struktūrų [Theodoridis; Koutroumbas, 2003]. Todėl klasterizavimo kokybės įvertinimas (angl. *evaluation*) yra vienas svarbiausių klasterizavimo proceso etapų. Jo metu gauti rezultatai parodo ar objektai (duomenys) buvo teisingai sugrupuoti į klasterius be išankstinės informacjos apie grupes. Egzistuoja 4 kriterijai klasterizavimo rezultatų kokybei įvertinti [FS+07]:

1. **Vidiniai** (angl. *internal*) kriterijai kokybę vertina lygindami objektų vienoduose klasteriuose panašumą ir objektų skirtumą skirtinguose klasteriuose. Deja, šio tipo kriterijai nėra universalūs, skirtingiems klasterizavimo metodams reikia parinkti skirtingus vidinius kriterijus.

2. **Išoriniai** (angl. *external*) kriterijai kokybę vertina lygindami gautus klasterius su jau iš anksto žinomomis duomenų klasėmis. Taigi, šiuo atveju vertiname neprižiūrimo mokymosi metodus su prižiūrimo mokymosi problemoms parengtais duomenimis. Nors labai tikėtina, kad neprižiūrimo mokymosi metodu sugeneruoti rezultatai bus blogesni, bet tai vis tiek labai vertingas vertinimo metodas. Tačiau svarbu atkreipti dėmesį, kad duomenis dažnai galima sugrupuoti keliais skirtingais būdais ir su duomenimis atėjusios etiketės (angl. *labels*) nebūtinai yra vienintelis galimas variantas.

3. **Rankiniai** (angl. *manual*) kriterijai, kai kokybė yra vertinama žmogaus. Praktikoje tokiu būdu visų sudarytų klasterių vertinimas užimtų labai daug laiko. Todėl dažniausiai vertintojui duodama pora objektų ir klausiama ar jie turėtų būti kartu, ar atskirai. Surinkę pakankamai rezultatų iš vertintojų, palyginame su rezultatais, gautais taikant klasterizavimo algoritmą. Taip pat šiuo atveju galima taikyti duomenų vizualizaciją, deja tai tampa ypač sudėtinga su didelės apimties duomenimis (tekstiniais dokumentais).

4. **Netiesioginiai** (angl. *indirect*) kriterijai įvertina ar klasterizavimas yra vertingas žingsnis, didesnės problemos sprendimui (pvz., klasterizavimas naudojamas vaizdų atpažinimui kaip tarpinis žingsnis matmenų kiekiui sumažinti). Todėl galime stebėti didesnės problemos sprendimo rezultatus su skirtingais klasterizavimo metodais (ar jų parametrais) ir parinkti tinkamiausią metodą.

Praktikoje, jei yra galimybė, dažniausiai naudojami išoriniai kriterijai, keletas jų yra:

1. **Rand indeksas** (toliau Rand) [Ran71] – teisingai suklasterizuotų objektų dalis:

$$Rand = \frac{TP + TN}{TP + FP + FN + TN}$$

1 lentelė. Klasterių kokybės vertinimas

	Priklauso klasei	Nepriklauso klasei
Priskirtas klasteriui	Teisingai priskirtas (angl. *true positive*) (TP)	Neteisingai priskirtas (angl. *false positive*) (FP)
Nepriskirtas klasteriui	Neteisingai nepriskirtas (angl. *false negative*) (FN)	Teisingai nepriskirtas (angl. *true negative*) (TN)

2. Homogeniškumas (angl. *homogeneity*) [RH07] – kiekvienam klasteriui priklauso objektai tik iš vienos klasės:

$$h = 1 - \frac{H(C|K)}{H(C)}$$

$$H(C) = -\sum_{c=1}^{|C|} \frac{n_c}{n} \cdot \log\left(\frac{n_c}{n}\right)$$

$$H(C|K) = -\sum_{c=1}^{|C|}\sum_{k=1}^{|K|} \frac{n_{c,k}}{n} \cdot \log\left(\frac{n_{c,k}}{n_k}\right)$$

3. Išsamumas (angl. *completeness*) [RH07] visi klasės objektai priklauso tik vienam klasteriui.

$$c = 1 - \frac{H(K|C)}{H(K)}$$

4. Eksperimentinis tyrimas

Dokumentų klasterizavimo eksperimentiniam tyrimui duomenų šaltiniu pasirinkau naujienų svetainės „Delfi“ 5 skirtingų kategorijų 2017 m. paskelbtus straipsnius ir, taikydamas skirtingus klasterizavimo metodus, bandžiau šiuos straipsnius priskirti pasirinktoms svetainės kategorijoms.

Eksperimento metu išbandžiau keturis kursiniame darbe paminėtus klasterizavimo algoritmus, o duomenis parengiau šiame darbe paminėtais būdais ir įvertinau gautų klasterių kokybę.

4.1. Duomenų išgavimo rezultatai

Pirmas eksperimentinio tyrimo žingsnis buvo gauti naujienų straipsnius. Neradęs jau paruošto duomenų rinkinio ar patogios sąsajos atsisiųsti didelius kiekius straipsnių iš populiariausių naujienų svetainių (`https://www.delfi.lt/`, `https://www.lrytas.lt/`, `https://www.15min.lt/`, `https://www.alfa.lt/`, `https://www.tv3.lt/`), su prašymu dėl tokios galimybės suteikimo kreipiausi į šias agentūras elektroniniu paštu. Tačiau naujienų agentūroms neatsiliepus į mano prašymą, ir, kad galėčiau tyrimo metu pasinaudoti naujienų svetainių straipsniais, nusprendžiau parašyti savo internetinį robotą. Internetiniam robotui rašyti pasinaudojau Scrapy biblioteka[9] (Programos kodas Nr. 3 priede).

Iš anksčiau išvardintų lietuviškų naujienų svetainių darbui pasirinkau „Delfi“. Tokį pasirinkimą lėmė šios svetainės plati straipsnių įvairovė, straipsnių puslapiuose esanti papildoma vertinga informacija[10] ir svarbiausia, archyvo funkcija[11], kur galima atlikti straipsnių paiešką pagal raktinį žodį, datą ir kategoriją. Nusprendžiau išgauti 2017 m. sausio 1 d.–gruodžio 31 d. archyve iš 5-ių skirtingų kategorijų po 1000 straipsnių. Kategorijas pasirinkau remdamasis tuo, kad, mano manymu, jas galėtų lengvai atskirti vieną nuo kitos eilinis vartotojas. Pasirinktos šios kategorijos: „Auto“, „Veidai“, „Sportas“, „Mokslas“ ir „Verslas“.

Po to, internetinio roboto pagalba išgavęs reikiamus straipsnius (duomenų rinkinį), atlikau duomenų valymą: panaikinau blogai nuskaitytus straipsnius (keletas straipsnių turėjo išskirtinį formatavimą nors vizualiai atrodė identiškai) ir straipsnius, turinčius mažiau nei 1000 simbolių tekstą (iš 5233 nuskaitytų straipsnių tolesnei analizei liko 4058[12], arba 78 % straipsnių). Tada, kad galėčiau straipsnius priskirti atitinkamoms kategorijoms, suvienodinau jų pavadinimus (pvz., „Auto“, „auto“, „Delfi auto“ pakeičiau į „Auto“).

4.2. Teksto filtravimo ir požymių išskyrimo rezultatai

Teksto filtravimui atlikau leksinę analizę, nereikšmingų žodžių panaikinimą ir kamieno atskyrimą. Sinonimų ir daugiareikšmių žodžių analizatoriaus ir lemuoklio, kuriuos galėčiau panaudoti

[9] `https://scrapy.org/`

[10] Ne tik pavadinimas ir tekstas, bet ir parašymo data, kategorija, įvadas (angl. *intro*) ir žymės (angl. *tags*)

[11] https://www.delfi.lt/archive/

[12] Auto – 895, Veidai – 779, Sportas – 760, Mokslas – 837, Verslas – 787 straipsnių; vidutiniškai 812 straipsnių.

dideliems kiekiams lietuviškų tekstų, nepavyko rasti[13].

Leksinei analizei panaudojau reguliaryjį reiškinį (angl. *regular expression*) : „`[\W\d_]+`“, kad pakeisčiau visus simbolius, kurie nėra raidės (`\W`) ir skaičius (`\d`) į tarpo simbolį ir tada tekstą suskaldžiau pagal tarpo simbolius. Nors yra keli atvejai, kai šis metodas neidealiai susitvarko su tekstu („1992-ųjų“, romėniškais skaičiais, „2 mln.“), bet manau gauti rezultatai yra pakankamai geri. Straipsnius sudarė vidutiniškai 415 žodžių (trumpiausias – 97, o ilgiausias – 3335 žodžius).

Nereikšmingiems žodžiams pašalinti pasinaudojau jau sudarytu žodynu[14](Pilnas žodynas Nr. 2 priede). Iš kiekvieno straipsnio pašalinta vidutiniškai po 85 žodžius arba ~21% žodžių.

Kamieno atskyrimui nusprendžiau panaudoti populiarią, taisyklėmis paremtą sistemą „Snowball“. Ši sistema atlieka analizę pagal pateiktas taisykles, todėl kiekvienai kalbai jos turi būti realizuotos atskirai. Populiariausia šios sistemos realizacija[15] yra ir lietuvių kalba[16]. Duomenų rinkinyje iš viso buvo 141370 unikalūs žodžiai, išgavus kamienus, liko 47707 unikalūs žodžių kamienai.

Požymių išskyrimui naudojau Scikit-learn[17] bibliotekoje realizuotą tf-idf metodą. Be papildomų nustatymų šis metodas grąžino 4058×47581 dydžio matricą (4058 – atskiri dokumentai, 47581 – požymiai). Deja, ši matrica buvo per didelė porai metodų (LM ir hierarchinio jungiamojo), todėl nusprendžiau pasinaudoti „*max_features*“ parametru ir palikti pusę požymių (23790). K-vidurkių ir DBSCAN metodai nebuvo smarkiai to paveikti.

4.3. Klasterizavimo metodai ir jų parametrų parinkimas

Klasterizavimui taip pat naudojau Scikit-learn biblioteką. Ši biblioteka realizuoja daug skirtingų klasterizavimo metodų[18], įskaitant ir mano analizuotus: K-vidurkių, lūkesčių-maksimizavimo, hierarchinio jungiamojo ir DBSCAN. Kiekvienas iš metodų turi papildomus parametrus, kuriuos galima nustatyti prieš klasterizavimą. Keletas prasmingų ir susijusių su mano ankstesne apžvalga parametrų:

- K-vidurkių
  - `n_clusters` – šis parametras nurodo, kiek klasterių bus sudaryta ir tuo pačiu kiek centroidų, kitaip tariant, tai atitinka *k*. Kadangi straipsnius parinkau iš 5 kategorijų, todėl šį parametrą taip pat nustačiau 5.
  - `init` – centroidų inicijavimo metodas. Pasirinkau k-means++.
  - `n_init` – ši k-vidurkių realizacija lokalaus maksimumo problemą sprendžia pakartotinai paleidžiant metodą ir šis parametras nurodo kiek kartų tai bus atlikta. Šiuo atveju palikau numatytą reikšmę – 10.

[13] VDU suteikia prieiga prie internetinio morfologinio anotatoriaus `http://donelaitis.vdu.lt/main.php?id=4&nr=7_2`, bet nėra patogaus būdo atlikti analizę su dideliais tekstų kiekiais.

[14] `https://gist.github.com/revelt/01524e76c6e5e0970d2d0fe8797e92ed`

[15] `https://snowballstem.org/`

[16] `https://github.com/snowballstem/snowball/blob/master/algorithms/lithuanian.sbl`

[17] https://scikit-learn.org

[18] `https://scikit-learn.org/stable/modules/clustering.html`

- `max_iter` – kiek iteracijų atlikti, palikau numatytą reikšmę – 300.
- `random_state` – k-vidurkių veikimui reikalingos atsitiktinės reikšmės, todėl norint rezultatus padaryti deterministinius, galima nurodyti atsitiktinumo inicializavimo reikšmę (angl. *random seed*) . Kad rezultatai tarp skirtingų bandymų išliktų stabilūs ir nepriklausytų nuo atsitiktinumo, nustačiau inicializavimo reikšmę – 42.

- Lūkesčių-maksimizavimo
  - `n_components` – atitinka k-vidurkių parametrą `n_clusters`.
  - `n_init, max_iter, random_state` – reiškia tą patį kaip ir k-vidurkių parametrai. `n_init, max_iter` palikau numatytas reikšmes, atitinkamai 1 ir 100, `random_state` nustačiau 42.
  - `init_params` – inicializavimo metodas. Čia palikau „k-means“ numatytą reikšmę.

- Hierarchinio jungiamojo
  - `n_clusters` – atitinka k-vidurkių parametrą.
  - `Linkage` – nurodo atstumo matavimo / jungimo metodą. Palaikomieji: tolimiausio kaimyno, vidutinių atstumų ir Ward metodas. Išbandžiau visus atskirai.

- DBSCAN
  - `eps, min_samples` – maksimalus atstumas iki kaimyno ir minimalus kaimynų kiekis. Kaip parinkau šiuos parametrus aprašyta prie rezultatų(4.4.4).

Skirtingų metodų implementacijos skirtingai palaiko panašumo funkcijas / įverčius, todėl nusprendžiau palikti numatytas reikšmes.

4.4. Rezultatai ir jų vertinimas

Kadangi iš anksto buvo žinomos straipsnių kategorijos (kurias galime laikyti klasėmis), todėl rezultatų vertinimui naudojau išorinius kriterijus. Tuo tarpu lyginant skirtingų klasterizavimo metodų rezultatus, vidiniai kriterijai nėra tinkami, nesvieni iš jų būtų palankesni vieniems metodams, kiti kitiems.

Žinant šias sąlygas nusprendžiau klasterizavimo rezultatus vertinti 4 skirtingais būdais[19]:

1. Pagal tinkamiausius požymius – k-vidurkių ir lūkesčių-maksimizavimo metodų sudaryti klasteriai turi centrus, todėl galime nustatyti, kurie požymiai geriausiai juos atitinka. Kiekvieno klasterio 10 tinkamiausių požymių pateikiau lentelėse.

[19] 1 ir 2 galime laikyti rankiniu vertinimu, o 3 ir 4 išoriniu.

2. Stebint klasterių dydžius – kiekvienai kategorijai priklauso panašus kiekis duomenų, todėl vien tik stebint sudarytų klasterių dydžius, galima spręsti apie jų kokybę.

3. Pagal išorinius kriterijus – Scikit-learn biblioteka palaiko daug klasterių vertinimo metodų ir visus iš mano paminėtų: Rand indeksas(Rand), homogeniškumas ir išsamumas.

4. Naudojant sumišimo matricą (angl. *confusion matrix*) – pavaizduojama kiek straipsnių yra kategorijose ir į kurį klasterį jie pateko[20]. Idealiu atveju (Stulpelių eilės tvarka nesvarbi), matrica atrodytų taip:

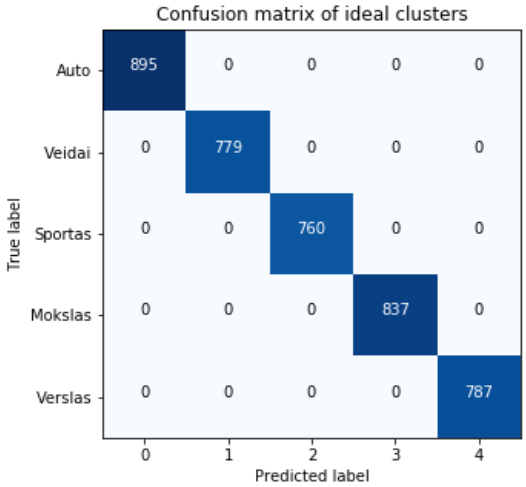

2 pav. Ideali Sumišimo matrica

2, 3 ir 4 vertinimus pateikiu dvejomis formomis. Pirma – tokius, kaip jie atrodė iš karto po klasterizavimo, kai jų eiliškumas buvo atsitiktinis ir antra – perrikiavus, kad būtų lengviau pastebėti, kurią kategoriją jie geriausiai atitinka. Šis perrikiavimas veikia taip: kiekvienam klasteriui priskiriame naują indeksą pagal tai, kuriai kategorijai daugiausia jo elementų priklauso. To pasekoje, klasteriai gali būti sujungti į vieną (tai ypač svarbu, jei klasterių skaičius būtų didesnis nei kategorijų).

4.4.1. K-vidurkių rezultatai

2 lentelė. Tinkamiausi klasterių požymiai

Klasteris	Požymiai									
0	rungtyn	komand	įvart	žaid	lyg	tašk	klub	ekip	pergal	rinktin
1	yr	buv	met	kur	film	žmon	lab	gal	dain	vis
2	eur	proc	met	lietuv	darb	yr	įmon	kain	telefon	kur
3	automobil	vair	eism	transport	model	kel	priemon	varikl	gal	yr
4	sport	varžyb	sportinink	lietuv	lenktyn	ral	met	čempion	viet	olimpin

[20] 1 lentelę galima laikyti 2 klasterių sumišimo matrica

Klasterių dydžiai: [393 1322 1221 671 451]
Rand: 0.450
Homogeniškumas: 0.535
Išsamumas: 0.576

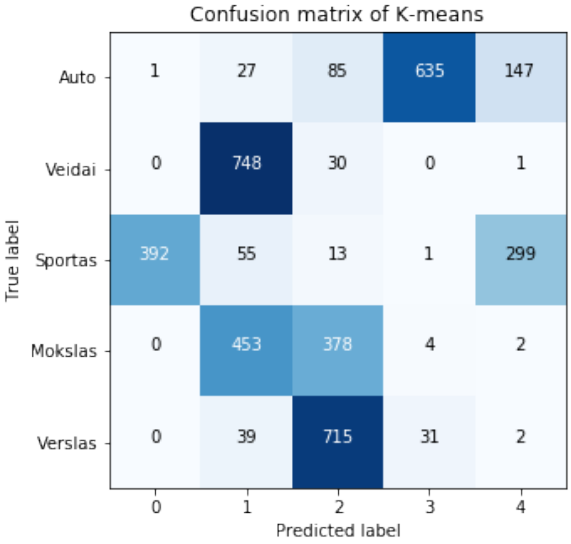

a)

Klasterių dydžiai: [671 1322 844 0 1221]
Rand: 0.489
Homogeniškumas: 0.519
Išsamumas: 0.618

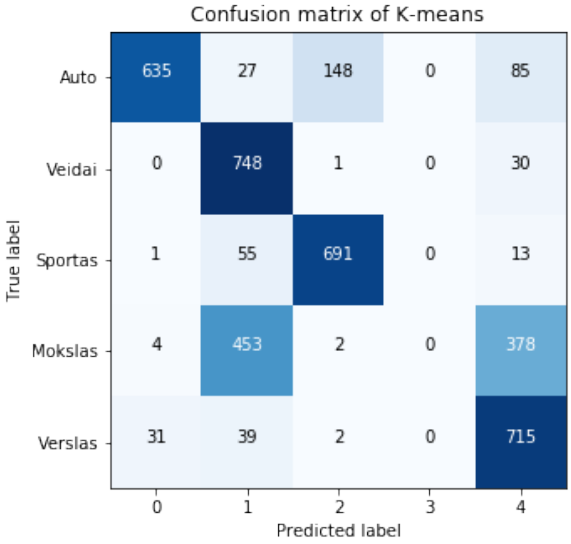

b)

3 pav. K-vidurkių algoritmo rezultatų sumišimo matrica a) nerikiuota ; b) rikiuota

Kaip matyti iš sumišimo matricos, k-vidurkių metodu visų kategorijų straipsniai buvo suskirstyti gana teisingai, išskyrus „Sporto“ ir „Mokslo“ kategorijų straipsnius. „Sporto“ kategorijos straipsniai pasidalino į du klasterius (0 ir 4), „Mokslo“ straipsniai irgi pasidalino į du klasterius (1 ir 2), be to, dar susimaišė su kitomis kategorijomis („Veidai“ ir „Verslas“). „Auto“ kategorijos straipsniai buvo sėkmingai atskirti.

Tai ką matome tarp straipsnių pasiskirstymo, taip pat galime pastebėti ir tinkamiausių požymių lentelėje. Vien tik skaitant juos, galime nuspėti kategorijų pavadinimus. Vienintelė išimtis 1 klasteris, pagal kurio požymius (pvz.: „yr“, „buv“, „met“…) sunkiau nuspėti temą, kuriai būtų galima priskirti.

Perrikiavus duomenis, 0 ir 4 klasteriai susijungė į vieną, „Sporto“ kategoriją reprezentuojantį klasterį.

4.4.2. Lūkesčių-maksimizavimo (LM) rezultatai

3 lentelė. Tinkamiausi klasterių požymiai

Klasteris	Požymiai									
0	mokslinink	yr	tyrim	žem	gal	kur	kosm	planet	met	buv
1	film	buv	yr	kur	met	dain	lab	koncert	vis	telefon
2	eur	proc	met	darb	lietuv	įmon	yr	kain	mokest	mln
3	komand	rungtyn	lietuv	čempion	įvart	tašk	pergal	viet	varžyb	žaid
4	automobil	vair	eism	transport	model	kel	gal	priemon	varikl	yr

Klasterių dydžiai: [386 1144 1035 785 708]
Rand: 0.545
Homogeniškumas: 0.583
Išsamumas: 0.604

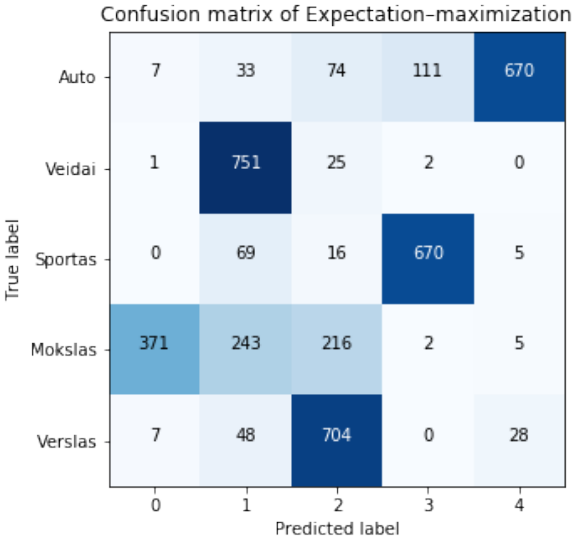

a)

Klasterių dydžiai: [708 1144 785 386 1035]
Rand: 0.545
Homogeniškumas: 0.583
Išsamumas: 0.604

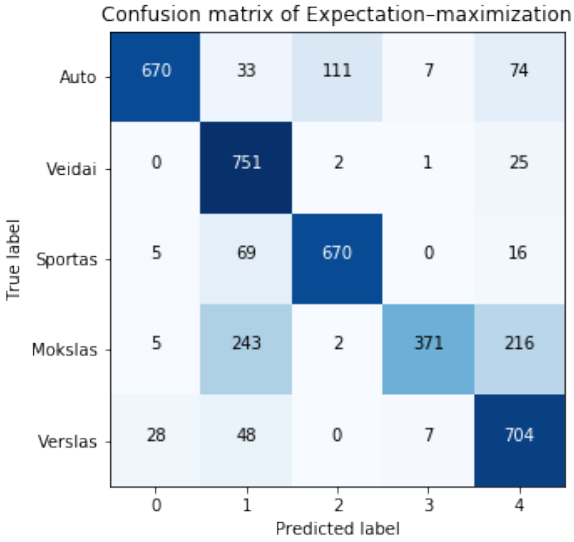

b)

4 pav. Lūkesčių-maksimizavimo algoritmo rezultatų sumišimo matrica a) nerikiuota ; b) rikiuota

LM metodas, kaip buvo galima tikėtis, sugeneravo į k-vidurkių metodą labai panašius klasterius. „Mokslas“ straipsniai pasiskirstė tarp trijų klasterių, du („Veidai“ ir „Verslas“) susimaišė su kitų kategorijų straipsniais ir vienas klasteris liko atskiras nuo kitų. „Auto“ ir „Sporto“ straipsniai buvo sėkmingai suklasterizuoti į atskirus klasterius.

Pagal klasterių požymius lengvai galime išskirti 5-ias kategorijas. Taip pat pagal šiuos rezultatus galima lengviau (nei k-vidurkių atveju) pastebėti apie ką rašo „Veidas“ kategorijos straipsniai. Išsiskiria požymiai: „film“, „dain“, „koncert“ – aiškiai kalbama apie pramoginius renginius.

Po perrikiavimo jokie klasteriai nesusijungė, tik pasikeitė jų eiliškumas.

4.4.3. Hierarchinio jungiamojo rezultatai

Tolimiausio kaimyno

Iš pateiktų sumišimo martricų matome, kad tolimiausio kaimyno metodo pateikti rezultatai buvo prasti. Į 0 klasterį pateko daugiau nei pusė visų straipsnių. Sėkmingai į du atskirus klasterius buvo atskirti tik „Sportas“ kategorijos straipsniai. Kiti klasteriai buvo sudaryti iš kelių kategorijų. Perrikiavus, du „Sporto“ klasteriai susijungė į vieną.

Vidutinių atstumų

Ward metodas

Klasterizuojant lietuviškus dokumentus Ward metodas, manyčiau, kad galėtų būti taikomas, nes beveik pusė straipsnių buvo priskirti vienam klasteriui, kiti buvo neblogai atskirti pagal kategorijas. „Auto“ ir „Verslas“ kategorijos buvo atskirtos į atskirus klasterius, „Sportas“ kategorijos

Klasterių dydžiai: [2096 1079 229 519 135]
Rand: 0.169
Homogeniškumas: 0.255
Išsamumas: 0.332

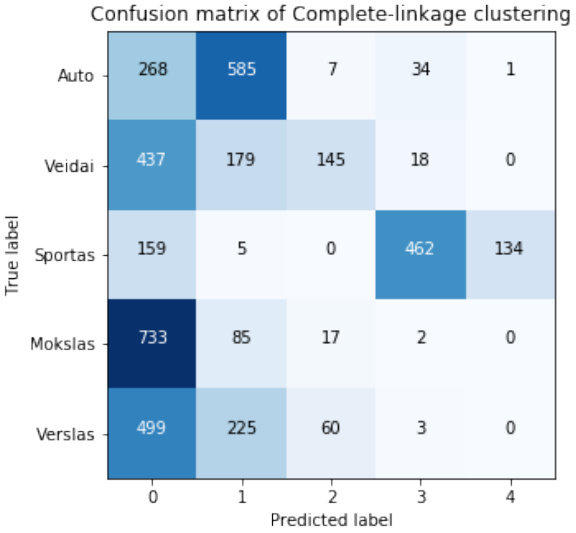

a)

Klasterių dydžiai: [1079 229 654 2096 0]
Rand: 0.195
Homogeniškumas: 0.253
Išsamumas: 0.354

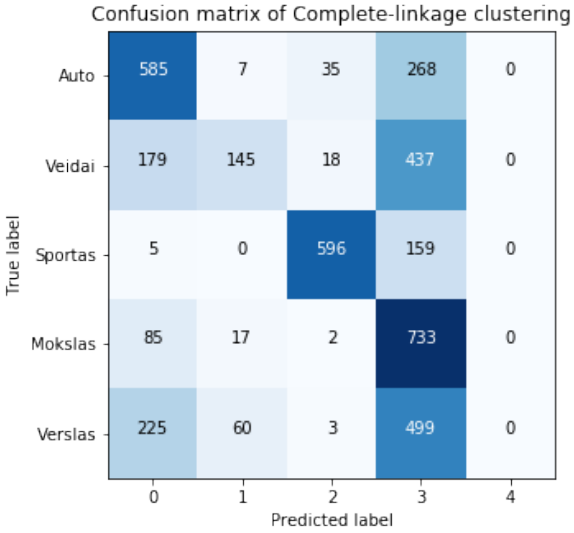

b)

5 pav. Tolimiausio kaimyno metodo rezultatų sumišimo matrica a) nerikiuota ; b) rikiuota

Klasterių dydžiai: [4049 3 2 1 3]
Rand: 0.000
Homogeniškumas: 0.002
Išsamumas: 0.165

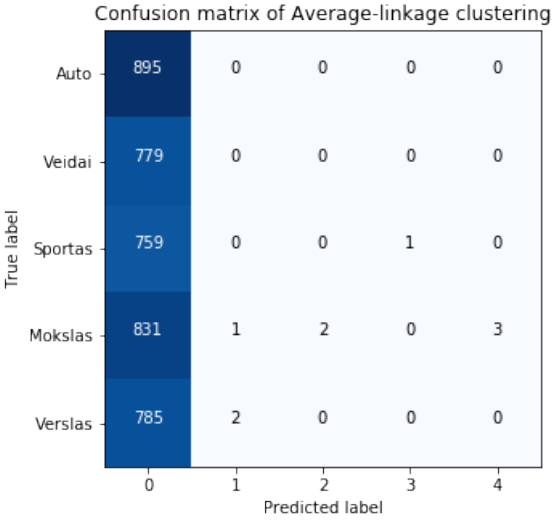

6 pav. Vidutinių atstumų metodo rezultatų sumišimo matrica

Kaip parodė tyrimo rezultatai, mažiausiai tinkamas lietuviškų tekstų klasterizavimui buvo vidutinių atstumų metodas. Pritaikius šį metodą, praktiškai visi straipsniai buvo priskirti vienam klasteriui.

straipsniai padalinti tarp 2 klasterių, o „Veidai“ ir „Mokslas“ kategorijų straipsniai pateko į vieną klasterį. Perrikiavus, „Sportas“ kategorijai atitikę klasteriai, susijungė į vieną.

Klasterių dydžiai: [1828 502 680 404 644]
Rand: 0.385
Homogeniškumas: 0.488
Išsamumas: 0.545

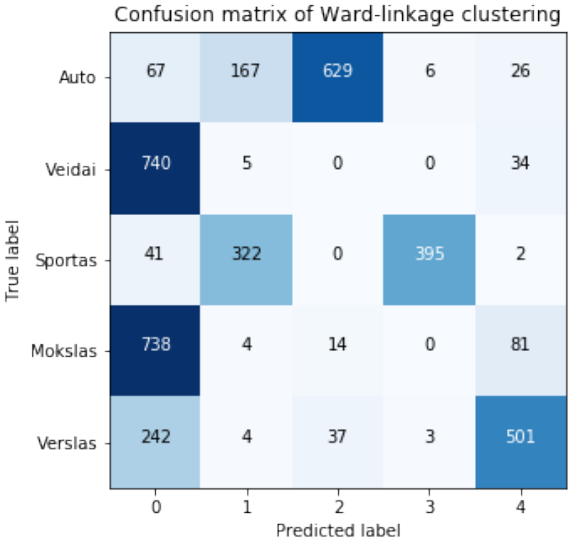

a)

Klasterių dydžiai: [680 1828 906 0 644]
Rand: 0.425
Homogeniškumas: 0.473
Išsamumas: 0.591

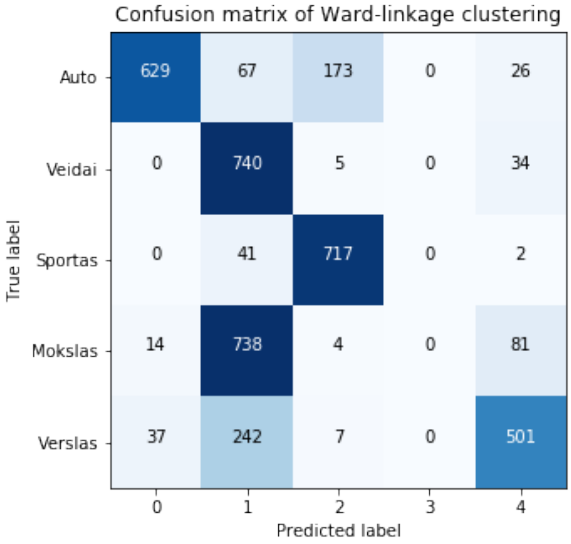

b)

7 pav. Ward metodo rezultatų sumišimo matrica a) nerikiuota ; b) rikiuota

4.4.4. DBSCAN rezultatai

Su DBSCAN metodu buvo sudėtingiau, nes kaip parametro nebuvo įmanoma nurodyti norimo klasterių skaičiaus, reikėjo išbandyti daug parametrų reikšmių kombinacijų. Deja, bet nei viena kombinacija nedavė tinkamo rezultato, todėl pakako stebėti klasterių dydžius ir kiti vertinimo metodai nebuvo reikalingi. `eps` parametrui – išbandžiau reikšmes nuo 0,6 iki 1,3; `min_samples` parametrui – išbandžiau reikšmes nuo 3 iki 8. Pilna rezultatų lentelė Nr. 1 priede. Taikant DBSCAN metodą gauti tokie pastebėjimai:

- Kai `eps` reikšmė buvo mažesnė nei 0,6, visi duomenys buvo priskiriami triukšmui, kai reikšmė didesnė nei 1,3 – visi duomenys buvo priskiriami vienam klasteriui;
- Didinat `min_samples` reikšmę, klasterių kiekis ir dydžiai mažėja. Reikšmės mažesnės nei 3 buvo netinkamos[21];
- Kai `eps` reikšmės buvo nuo 0,6 iki 1,1 (imtinai) dauguma duomenų buvo priskiriami triukšmui, bet nuo 1,2 ir daugiau – dauguma duomenų buvo priskiriami vienam klasteriui;
- Dažniausiai sudaromi dideli kiekiai mažų klasterių (daugiausia buvo sudaryti 177).

Galima daryti išvadą , kad duomenys buvo per daug tolygaus (nėra atskirų duomenų „sutirštėjimų“[22]. (anlg. blob) tankio, kad būtų sėkmingai suklasterizuoti taikant šį metodą.

[21] Išsamiau apie tai pirmame darbe.
[22] Tai gali būti dėl didelio duomenų dimensingumo

4.5. Išvados

Eksperimentinio tyrimo metu buvo pasiektas užsibrėžtas tikslas – aprašyti lietuviškų tekstinių dokumentų parengimo klasterizavimui žingsniai, palygintas skirtingų klasterizavimo metodų veikimas taikant juos darbui su lietuviškais dokumentais, įvertinta rezultatų kokybė ir pateikti pasiūlymai.

1. Tyrimui buvo sudarytas didelės apimties tekstinis duomenų rinkinys iš 5-ių skirtingų kategorijų ir kiekviena kategorija iš vidutiniškai 812 skirtingų straipsnių.

2. Duomenų rinkiniui buvo atlikta leksinė analizė, pašalinti nereikšmingi žodžiai ir išskirti žodžių kamienai. Tada duomenys buvo paversti į verktorinę formą naudojant tf-idf metodą.

3. Eksperimentas buvo atliekamas su 4-ių tipų klasterizavimo metodais: k-vidurkių, lūkesčių-maksimizavimo, hierarchinio jungiamojo (su tolimiausio kaimyno, vidutinių atstumų ir Ward atstumo matavimo / jungimo metodais) ir DBSCAN.

4. Eksperimento metu gautų rezultatų kokybės vertinimas buvo atliktas 4-iais būdais: tinkamiausių požymių išskyrimo, klasterių dydžių stebėjimo, taikant išorinius kriterijus (Rand indeksas, homogeniškumas, išsamumas) ir sumišimo matricas.

Kaip parodė eksperimentinio tyrimo rezultatai, lietuviškų tekstų klasterizavimui mažiausiai pritaikytas yra DBSCAN metodas, nes tyrimo metu buvo gauti prasčiausi rezultatai ir reikalavo daugiausia parametrų derinimo. Taip pat prasti rezultatai gauti naudojant vidutinių atstumų ir tolimiausio kaimyno metodus. Ward metodas pateikė pakankamai gerus rezultatus ir gali būti naudojamas lietuviškų tekstų klasterizavimui.

Dėl rezultatų interpretavimo paprastumo ir geros jų kokybės, skaldantys / centroidais paremti metodai geriausiai tinka lietuviškiems tekstiniams duomenims klasterizuoti. K-vidurkių ir LM metodus galima laikyti geriausiai pritaikytais lietuviškų tekstų klasterizavimui. K-vidurkių algoritmo sugeneruoti klasteriai atitiko keturias, o LM algoritmo – visas penkias kategorijas.

Manau, kad eksperimentinius tyrimus su skirtingai paruoštais lietuviškais tekstiniais dokumentais ir pritaikant įvairius klasterizavimo metodus, reikėtų tęsti ir ateityje.

Literatūra

[ATL13] Salem Alelyani, Jiliang Tang ir Huan Liu. Feature selection for clustering: a review. *Data clustering: algorithms and applications*, 29:110–121, 2013.

[BB04] Marco Baroni ir Sabrina Bisi. Using cooccurrence statistics and the web to discover synonyms in a technical language. *Lrec*, 2004.

[FPS96] Usama Fayyad, Gregory Piatetsky-Shapiro ir Padhraic Smyth. From data mining to knowledge discovery in databases. *Ai magazine*, 17(3):37, 1996.

[FS+07] Ronen Feldman, James Sanger ir k.t. *The text mining handbook: advanced approaches in analyzing unstructured data*. Cambridge university press, 2007.

[KCA14] Ammar Ismael Kadhim, Yu-N Cheah ir Nurul Hashimah Ahamed. Text document preprocessing and dimension reduction techniques for text document clustering. *Artificial intelligence with applications in engineering and technology (icaiet), 2014 4th international conference on*. IEEE, 2014, p.p. 69–73.

[MCC+13] Tomas Mikolov, Kai Chen, Greg Corrado ir Jeffrey Dean. Efficient estimation of word representations in vector space. *Arxiv preprint arxiv:1301.3781*, 2013.

[MCS14] Phillip Marksberry, Joshua Church ir Michael Schmidt. The employee suggestion system: a new approach using latent semantic analysis. *Human factors and ergonomics in manufacturing & service industries*, 24(1):29–39, 2014.

[MPP] K Mugunthadevi, SC Punitha ir M Punithavalli. Survey on feature selection in document clustering.

[Pia14] Karolina Piaseckienė. Statistiniai metodai lietuvių kalbos sudėtingumo analizėje. Disertacija. Vilnius University, 2014.

[PSM14] Jeffrey Pennington, Richard Socher ir Christopher Manning. Glove: global vectors for word representation. *Proceedings of the 2014 conference on empirical methods in natural language processing (emnlp)*, 2014, p.p. 1532–1543.

[Ran71] William M Rand. Objective criteria for the evaluation of clustering methods. *Journal of the american statistical association*, 66(336):846–850, 1971.

[RH07] Andrew Rosenberg ir Julia Hirschberg. V-measure: a conditional entropy-based external cluster evaluation measure. *Proceedings of the 2007 joint conference on empirical methods in natural language processing and computational natural language learning (emnlp-conll)*, 2007.

[Spa72] Karen Sparck Jones. A statistical interpretation of term specificity and its application in retrieval. *Journal of documentation*, 28(1):11–21, 1972.

[Utk09] Anrdius Utka. Dažninis rašytinės lietuvių kalbos žodynas: 1 milijono žodžių morfologiškai anotuoto tekstyno pagrindu. *Kaunas: vytauto didžiojo universitetas*, 2009.

Priedas Nr. 1
DBSCAN rezltatų lentelė

ε	Min	Triukšmas	Klasterių kiekis	10 didžiausių klaserių
0.6	3	3989	18	11, 5, 5, 4, 4, 4, 3, 3, 3, 3
0.6	4	4025	6	11, 5, 5, 4, 4, 4
0.6	5	4037	3	11, 5, 5
0.6	6	4048	1	10
0.6	7	4048	1	10
0.6	8	4048	1	10
0.7	3	3946	27	14, 9, 6, 6, 5, 5, 5, 4, 4, 3
0.7	4	4001	9	14, 9, 6, 6, 5, 5, 4, 4, 4
0.7	5	4014	6	14, 9, 6, 5, 5, 5
0.7	6	4031	3	14, 7, 6
0.7	7	4037	2	14, 7
0.7	8	4044	1	14
0.8	3	3870	47	14, 10, 9, 8, 6, 6, 5, 5, 5, 5
0.8	4	3976	13	14, 9, 9, 8, 6, 6, 5, 5, 4, 4
0.8	5	4001	7	14, 9, 9, 8, 6, 6, 5
0.8	6	4012	5	14, 9, 9, 8, 6
0.8	7	4018	4	14, 9, 9, 8
0.8	8	4027	3	14, 9, 8
0.9	3	3649	85	24, 21, 15, 13, 10, 10, 10, 9, 8, 7
0.9	4	3801	38	23, 21, 15, 12, 10, 10, 10, 9, 7, 7
0.9	5	3886	19	23, 21, 12, 10, 10, 10, 9, 9, 7, 7
0.9	6	3911	16	23, 21, 10, 9, 9, 9, 8, 7, 7, 7
0.9	7	3950	10	23, 21, 10, 9, 9, 8, 7, 7, 7, 7
0.9	8	3989	5	23, 18, 10, 9, 9
1	3	3172	155	39, 33, 33, 27, 23, 19, 17, 16, 13, 12
1	4	3428	80	39, 33, 30, 27, 23, 19, 15, 13, 13, 12
1	5	3566	50	39, 33, 27, 25, 23, 19, 13, 13, 12, 12
1	6	3654	39	33, 28, 27, 23, 22, 19, 13, 12, 12, 12
1	7	3778	20	31, 28, 25, 23, 22, 19, 12, 12, 12, 11
1	8	3831	15	31, 28, 23, 20, 19, 17, 12, 12, 10, 10
1.1	3	2287	177	144, 138, 121, 89, 88, 66, 63, 49, 49, 41
1.1	4	2564	110	143, 107, 89, 87, 64, 48, 48, 47, 41, 38
1.1	5	2763	90	131, 75, 70, 60, 48, 41, 41, 38, 37, 36
1.1	6	2930	71	128, 72, 56, 43, 40, 38, 37, 37, 36, 34
1.1	7	3157	47	125, 58, 54, 43, 40, 38, 34, 33, 32, 30
1.1	8	3231	43	75, 57, 51, 43, 40, 38, 33, 33, 32, 29
1.2	3	1029	47	2825, 10, 10, 9, 8, 7, 7, 7, 7, 6
1.2	4	1160	26	2763, 10, 9, 8, 7, 7, 7, 7, 6, 6
1.2	5	1273	19	2654, 23, 10, 9, 8, 7, 7, 7, 7, 6
1.2	6	1387	13	2580, 16, 9, 9, 8, 7, 7, 7, 6, 6
1.2	7	1496	13	2470, 11, 9, 9, 9, 8, 7, 7, 7, 7
1.2	8	1616	6	2403, 9, 9, 7, 7, 7
1.3	3	72	1	3986
1.3	4	79	1	3979
1.3	5	89	1	3969
1.3	6	95	1	3963
1.3	7	105	1	3953
1.3	8	117	1	3941

Priedas Nr. 2
Nereikšmingų žodžių sąrašas

a abi abidvi abiejose abiejų abiejuose abiem abipus abu abudu aha ai aj ana anaiptol anaisiais anąja anąją anajai anajam anajame anąjį anapus anas anąsias anasis ane anei aniedvi anieji aniesiems anoji anojo anojoje anokia anoks anosiomis anosioms anosios anosiose anot ant antai anųjų anuodu anuoju anuosiuose anuosius apie aplink ar arba argi arti aš aukščiau be bei beje bemaž bene bent bet betgi beveik dar dargi daugmaž deja dėka dėl dėlei dėlto ech ei ej et gal galbūt galgi gan gana gi greta į idant iki įkypai ir irgi iš išilgai įstrižai išvis it itin ja ją jaisiais jąja jąją jajai jajam jąsias jei jeigu ji jį jiedu jiedvi jieji jiesiems jinai jis jisai jo jog joji jojo jojoje jokia joks josiomis josioms josios josiose judu judvi jųjų juk jumis jums jumyse juo juodu juosiuose juosius jus jūs jūsiškė jūsiškis jūsų kad kada kadangi kai kaip kaipgi kas katra katras katriedvi katruodu kažin kažkas kažkatra kažkatras kažkokia kažkoks kažkuri kažkuris kiaurai kiek kiekvienas kieno kita kitas kitokia kitoks kodėl kokia koks kol kolei kone kuomet kur kurgi kuri kuriedvi kuris kuriuodu lai lig ligi link lyg man manaisiais manąja manąją manajai manajam manajame manąjį manas manasai manąsias manasis mane manęs manieji maniesiems manim manimi maniškė maniškis mano manoji manojo manojoje manosiomis manosioms manosios manosiose manųjų manuoju manuosiuose manuosius manyje mat maždaug mažne mes mudu mudvi mumis mums mumyse mus mūsiškė mūsiškis mūsų na nagi ne nė nebe nebent negi negu nei nejau nejaugi nekaip nelyginant nes net netgi netoli neva nors nuo o ogi oho oi oj pačiais pačiam pačiame pačiu pačių pačiuose pačius paeiliui pagal pakeliui pala palaipsniui palei pas pasak paskos paskui paskum pat pati patį patiems paties pats patys per pernelyg pirm pirma pirmiau po prie prieš priešais pro pusiau rasi rodos šalia sau savaisiais savąja savąją savajai savajam savajame savąjį savas savasai savąsias savasis save savęs savieji saviesiems savimi saviškė saviškis savo savoji savojo savojoje savosiomis savosioms savosios savosiose savųjų savuoju savuosiuose savuosius savyje še ši šį šiaisiais šiąja šiąją šiajai šiajam šiajame šiapus šiąsias šiedvi šieji šiesiems šįjį šioji šiojo šiojoje šiokia šioks šiosiomis šiosioms šiosios šiosiose šis šisai šit šita šitas šitiedvi šitokia šitoks šituodu šiųjų šiuodu šiuoju šiuosiuose šiuosius skersai skradžiai stačiai štai su sulig ta tačiau tad tai taigi taip taipogi taisiais tąja tąją tajai tajam tajame tąjį tamsta tarp tarsi tartum tarytum tas tasai tąsias tau tavaisiais tavąja tavąją tavajai tavajam tavajame tavąjį tavas tavasai tavąsias tavasis tave tavęs tavieji taviesiems tavimi taviškė taviškis tavo tavoji tavojo tavojoje tavosiomis tavosioms tavosios tavosiose tavųjų tavuoju tavuosiuose tavuosius tavyje te tegu tegul tiedvi tieji ties tiesiems tiesiog tik tikriausiai tiktai to toji tojoje tokia toks tol tolei toliau tosiomis tosioms tosios tosiose tu tųjų tūlas tuodu tuoju tuosiuose tuosius turbūt už užtat užvis va vai vau vėl vėlgi viduj vidury vien vienas vienokia vienoks vietoj virš viršuj viršum vis visa visas visgi visokia visoks vos ypač žemiau

Priedas Nr. 3

Kodas

Listing 1: Internetinio roboto kodas

```
# -*- coding: utf-8 -*-
import re
import scrapy

class DelfiSpider(scrapy.Spider):
    name = 'delfi'

    custom_settings = {
        'LOG_FILE': 'log.txt',

        'FEED_FORMAT': 'json',
        'FEED_URI': 'delfi.json',
        'FEED_EXPORT_ENCODING': 'utf-8',

        'CONCURRENT_REQUESTS_PER_DOMAIN' : '1',

        'AUTOTHROTTLE_ENABLED' : 'True',
        'AUTOTHROTTLE_START_DELAY' : '5.0',
        'AUTOTHROTTLE_MAX_DELAY' : '60.0',
        'AUTOTHROTTLE_TARGET_CONCURRENCY' : '1.0',
        'AUTOTHROTTLE_DEBUG' : 'True',

        'HTTPCACHE_ENABLED' : 'True',
        'HTTPCACHE_EXPIRATION_SECS' : '0',  # Never expire.
    }
    allowed_domains = ['delfi.lt']
    # Articles from all channles and categories during 01.01.2017 - 01.01.2018 period
    archive_url =
     'https://www.delfi.lt/archive/index.php?fromd=01.01.2017&tod=01.01.2018&channel={}&category=0&query=&page=1'
    start_urls = [archive_url.format('600'), # Auto
                  archive_url.format('903'), # Sportas
                  archive_url.format('906'), # Veidai
                  archive_url.format('907'), # Verslas
                  archive_url.format('908'), # Mokslas
                 ]

    def parse(self, response):
        match = re.search(r'&channel=(\d+).+&page=(\d+)', response.request.url)
        channel = match.group(1)
        page = int(match.group(2))

        for num, article in enumerate(response.css('.CBarticleTitle::attr(href)').extract()):
            # Skip video articles
            if "/video/" in article:
                self.logger.info('Skip (video) article {}'.format(article))
                continue
            self.logger.info('Cha: {}, req {}/1000 article: {}'.format(channel, (page-1)*100+num+1, article))
            yield scrapy.Request(url=article, callback=self.parse_article)

        next_page = response.css('.next::attr(href)').extract_first()
        next_page = ''.join(next_page.split())
        # parsing up to 11 page because expecting 1000 articles, but some are skipped (video)
```

```
52          if (next_page is not None) and (page < 11):
53              yield response.follow(next_page, callback=self.parse)
54
55      def parse_article(self, response):
56          url = response.request.url
57          categorys = response.css('[itemprop=title]::text').extract()
58          if categorys == []: # If article is missing categorys extract them from url
59              categorys = re.search(r'https:\/\/www\.delfi\.lt\/(\w+)\/', url).group(1)
60          yield {
61              'title': response.css('h1::text').extract_first().strip(),
62              'date': response.css('[class$=source-date]::text').extract_first(),
63              'categorys': categorys,
64              'intro': " ".join(response.xpath('//*[@itemprop]/b//text()').extract()),
65              'text': " ".join(response.xpath('//*[@itemprop="articleBody"]/p//text()').extract()),
66              'tags': response.css('.ttl_link::text').extract(),
67              # 'body': response.body_as_unicode(),
68              'url' : url,
69          }
```

Listing 2: Analizės kodas

```
import json
with open("delfi.json", "r") as read_file:
    data = json.load(read_file)

cleaned_data = []
for d in data:
    if d["categorys"] in ("projektai", "m360") or len(d["text"]) < 1000:
        continue
    elif d["categorys"] == 'sportas':
        d["categorys"] = 'Sportas'
    elif d["categorys"][0].startswith('DELFI '):
        d["categorys"] = d["categorys"][0][6:]
    elif isinstance(d["categorys"], list):
        d["categorys"] = d["categorys"][0]
    cleaned_data.append(d)
cleaned_data = [d for d in cleaned_data if d["categorys"] in ("Verslas", "Mokslas", "Veidai", "Auto",
    "Sportas")]
print("From {} to {}.".format(len(data), len(cleaned_data)))
import re
import subprocess

num_tok, nostop_tokens, num_stems = 0, 0, 0

text_file = open("Lithuanian stop words", "r")
stopwords = text_file.read().split("\n")

for d in cleaned_data:#log_progress(cleaned_data):

    # if intro in bigger then text
    if len(d['text']) < len(d['intro']):
        print(d['text'] + '\n' + len(d['intro']))

    # tokenize & lowercase
    tokens = re.sub("[\W\d_]+", " ", d["text"]).lower().split()
    num_tok += len(tokens)

    # remove stop words
    new_tokens = [words for words in tokens if words not in stopwords]
    nostop_tokens += len(new_tokens)

    # steam
    with open("tokens.txt", "w") as token_file:
        token_file.write("\n".join(new_tokens))
    args = ("./stemwords", "-l", "lt", "-i", "tokens.txt", "-o", "stems.txt")
    popen = subprocess.Popen(args, stdout=subprocess.PIPE)
    popen.wait()
    with open("stems.txt", "r") as stem_file:
        stems = stem_file.read().split("\n")

    # put into dic
    d["stems"] = stems
    num_stems += len(stems)

print("In total tokens: {}, stop words removed: {}, stems: {}".format(num_tok, num_tok - nostop_tokens,
    num_stems))
text_file.close()
print(len([s for s in d['stems'] for d in data]))
# save as file
```

```
with open("delfi_pre.json", "w") as write_file:
    json.dump(cleaned_data, write_file)

import json
import numpy as np
with open("delfi_pre.json", "r") as read_file:
    data = json.load(read_file)

stems = [" ".join(d["stems"]) for d in data]
category_names = ['Auto', 'Veidai', 'Sportas', 'Mokslas', 'Verslas']
categorys = np.array([category_names.index(d["categorys"]) for d in data])

from sklearn.feature_extraction.text import TfidfVectorizer

vectorizer = TfidfVectorizer(max_features=(47581 // 2)) # half of total number of features
%time X = vectorizer.fit_transform(stems)
print(X.shape)



from sklearn.cluster import KMeans, DBSCAN, AgglomerativeClustering
from sklearn.mixture import GaussianMixture

K = 5
jobs = -1

KMtitle = "K-means"
KMmodel = KMeans(n_clusters=K,
                 n_jobs=jobs,
                 random_state=42,)

EMtitle = "-Expectationmaximization"
EMmodel = GaussianMixture(n_components=K,
                          covariance_type='diag',
                          random_state=42,)

ACtitle = "Complete-linkage clustering"
ACmodel = AgglomerativeClustering(n_clusters=K,
                                  linkage='complete',)
AAtitle = "Average-linkage clustering"
AAmodel = AgglomerativeClustering(n_clusters=K,
                                  linkage='average',)
AWtitle = "Ward-linkage clustering"
AWmodel = AgglomerativeClustering(n_clusters=K,
                                  linkage='ward',)
DBSCANtitle = "DBSCAN"
DBSCANmodel = DBSCAN(n_jobs = jobs,)

models = [{"model": KMmodel, "title": KMtitle},
          {"model": EMmodel, "title": EMtitle},
          {"model": ACmodel, "title": ACtitle},
          {"model": AAmodel, "title": AAtitle},
          {"model": AWmodel, "title": AWtitle},
          {"model": DBSCANmodel, "title": DBSCANtitle},
         ]



import itertools
```

```
116 import matplotlib.pyplot as plt
117 from sklearn.metrics import *
118 from scipy.stats import mode
119
120 def get_new_labels(clusters):
121     new_labels = np.zeros_like(clusters)
122     print("New labels:")
123     for i in range(K):
124         mask = (clusters == i)
125         closest_category = mode(categorys[mask])[0][0]
126         new_labels[mask] = closest_category
127         print("{} -> {}({})".format(i, closest_category, category_names[closest_category]))
128     print(np.bincount(new_labels))
129     return new_labels
130
131 def print_top_terms(model):
132     print("Top terms per cluster:")
133     centers = model.cluster_centers_ if isinstance(model, KMeans) else model.means_
134     order_centroids = centers.argsort()[:, ::-1]
135     terms = vectorizer.get_feature_names()
136     for i in range(K):
137         print("Cluster %d:" % i, end='')
138         for ind in order_centroids[i, :10]:
139             print(' %s' % terms[ind], end='')
140         print()
141
142 def print_metrics(y_pred):
143     print("Clustering print_metrics:")
144     print(" Rand   Mutual information   Homogeneity   Coompleteness   V-measure    Fowlkes mallows")
145     print("{0:.3f}               {1:.3f}         {2:.3f}           {3:.3f}       {4:.3f}      {5:.3f}"
146       .format(adjusted_rand_score(categorys, y_pred),
147               adjusted_mutual_info_score(categorys, y_pred),
148               homogeneity_score(categorys, y_pred),
149               completeness_score(categorys, y_pred),
150               v_measure_score(categorys, y_pred),
151               fowlkes_mallows_score(categorys, y_pred),
152               ))
153
154 def plot_confusion_matrix(y_pred, title='clusters'):
155     cm = confusion_matrix(categorys, y_pred)
156     plt.figure(figsize=(5,5))
157     plt.imshow(cm, interpolation='nearest', cmap = plt.cm.Blues)
158     plt.title("Confusion matrix of " + title)
159     tick_marks = np.arange(len(category_names))
160     plt.yticks(tick_marks, category_names)
161     plt.ylabel('True label')
162     plt.xlabel('Predicted label')
163
164     # put numbers inside cells
165     thresh = cm.max() / 2.
166     for i, j in itertools.product(range(cm.shape[0]), range(cm.shape[1])):
167         plt.text(j, i, format(cm[i, j], 'd'),
168                  horizontalalignment="center",
169                  color="white" if cm[i, j] > thresh else "black")
170     plt.show()
171
172 def metrics_and_martix(clusters):
173     print_metrics(clusters)
174     plot_confusion_matrix(clusters, title=m['title'])
```

```
    new_labels = get_new_labels(clusters)
    print_metrics(new_labels)
    plot_confusion_matrix(new_labels, title=m['title'])

for m in models:
    model = m['model']
    print('\n' + m['title'] + " results")

    if m['title'] == KMtitle:
        %time clusters = model.fit_predict(X)
        print(np.unique(clusters, return_counts=True)[1])

        print_top_terms(model)
        metrics_and_martix(clusters)

    elif m['title'] == EMtitle:
        %time model.fit(X.toarray())
        clusters = model.predict(X.toarray())
        print(np.unique(clusters, return_counts=True))

        print_top_terms(model)
        metrics_and_martix(clusters)

    elif m['title'] in [ACtitle, AAtitle, AWtitle]:
        %time clusters = model.fit_predict(X.toarray())
        print(np.unique(clusters, return_counts=True))

        metrics_and_martix(clusters)

    elif m['title'] == DBSCANtitle:
        for e in [0.6, 0.7, 0.8, 0.9, 1.0, 1.1, 1.2, 1.3]:
            for m in [3, 4, 5, 6, 7, 8]:
                model.set_params(eps = e, min_samples = m,)
                clusters = model.fit_predict(X)

                results = np.unique(clusters, return_counts=True)
                if results[0][0] == -1: #if there was noise
                    n_noise    = results[1][0]
                    n_clusters = np.sort(results[1][1:])[::-1]
                else:
                    n_noise    = 0      #if there was no noise
                    n_clusters = np.sort(results[1])[::-1]
                print (" =%.1f min=%i: noise=%4i clusters=%3i top10=%s"
                       %(e, m, n_noise, len(n_clusters), n_clusters[:10]))
    else:
        print(m)
```